

1 Osnovna znanja

1. Definiraj i na primjeru odredi signifikantne znamenke broja.

Neka je a neki realan broj, a a^* njegova aproksimacija. Prvih n znamenaka od a^* za koje vrijedi:

$$\Delta a^* \leq \frac{1}{2} \cdot 10^{m-n+1}$$

gdje je $a^* = b_m^* \cdot 10^m + b_{m-1}^* \cdot 10^{m-1} + \dots + b_n^* \cdot 10^{m-n+1} + \dots$ nazivamo **signifikantne**.

Primjer:

$$a = 9.35, \quad a^* = 9.141592$$

$$a^* = 9 \cdot 10^0 + 1 \cdot 10^{-1} + 4 \cdot 10^{-2} + \dots \implies m = 0$$

$$\Delta a^* = |a - a^*| = 0.208408 \leq \frac{1}{2} \cdot 10^{-1} = \frac{1}{2} \cdot 10^{0-n+1}$$

$$\implies -1 = 0 - n + 1 \implies n = 2$$

2. Objasni kako se određuje ocjena pogreške u izračunavanju vrijednosti funkcije $f : \mathbb{R}^n \rightarrow \mathbb{R}$, ako su zadane pogreške u varijablama.

- Predpostavimo da znamo pogrešku u varijabli, Δx^*
- iskoristi se Lagrangeov teorem na zadanu funkciju
- sada razliku između stvarne vrijednosti funkcije i aproksimacije, Δz^* , možemo aproksimirati kao $\Delta z^* \approx |f'(x)| \cdot \Delta x^*$
- Kada imamo funkciju više varijabli, prethodna aproksimacija ostaje samo se umnoži prve derivacije i pogreške u toj varijabli sumiraju za svaku varijablu, vidi primjer
- *za detaljniji izvod vidi objavljenu skriptu*

Primjer: Ocijeni grešku u $(x^*, y^*, z^*) = (0.5, 4, 1)$

$$f : \mathbb{R}^3 \rightarrow \mathbb{R}, \quad f(x, y, z) = x^2 + 2y - 3z$$

$$x = 0.5 \pm 0.07, \quad y = 4 \pm 0.05, \quad z = 1 \pm 0.03$$

$$\nabla f = \begin{bmatrix} 2x \\ 2 \\ -3 \end{bmatrix}$$

$$\implies \Delta z^* = |2 \cdot 0.5| \cdot 0.07 + |2| \cdot 0.05 + |-3| \cdot 0.03 = 0.26$$

Još nekoliko jednostavnih funkcija za usmeni:

- $f(x, y) = xy + x - y$
- $f(x, y, z) = 7x - y^2 + z$
- $f(x, y) = \sin(x) + y^3$

3. Objasni inverzni problem u računanju vrijednosti funkcije, odnosno kako se određuje pogreška u varijablama.

- Koristimo **princip jednakih efekata**, tj. pretpostavimo da su pogreške za svaku varijablu iste, pa našu pogrešku u vrijednosti funkcije (koja nam je poznata) možemo zapisati kao:

$$\Delta z^* \approx n \cdot \left| \frac{\partial f(x_1^*, \dots, x_n^*)}{\partial x_i} \right| \cdot \Delta x_i^*$$

$$\implies \Delta x_i^* \approx \frac{\Delta z^*}{n \cdot \left| \frac{\partial f(x_1^*, \dots, x_n^*)}{\partial x_i} \right|}$$

Primjer: Pretpostavimo da trebamo pravokutnik površine 6 ± 0.75 , kolika smije biti greška u duljini stranica.

$$\begin{aligned} f(x, y) = xy &\implies \nabla f = \begin{bmatrix} y \\ x \end{bmatrix}, \quad x^* = 2, \quad y^* = 3 \\ &\implies \Delta x^* \approx \frac{0.75}{2 \cdot y^*} \approx 0.125 \\ &\implies \Delta y^* \approx \frac{0.75}{2 \cdot x^*} \approx 0.1875 \\ &\implies x = 2 \pm 0.125, \quad y = 3 \pm 0.1875 \end{aligned}$$

Još par primjera za usmeni:

- $f(x) = \frac{4}{3}x^3\pi$, $x^* = 3$, $\Delta z^* = 0.5$
- $f(x, y) = 2(x + y)$, $x^*, y^* = 2.5$, $\Delta z^* = 0.25$

4. Objasni razliku između interpolacije i aproksimacije.

Interpolaciju koristimo kada tražimo funkciju koja predstavlja niz podataka, te u zadanim točkama postiže već točno predodređene vrijednosti, ali zato između čvorova dopuštamo odstupanja, koliko god velika.

Aproksimacijom, cilj nam je neku funkciju aproksimirati sa drugom, sa kojom je možda lakše računati i slično, ali ne tako da gledamo jednakost u određenim točkama, nego da odstupanje jedne od druge svedemo na minimum na cijeloj nekoj domeni, te onda našu aproksimaciju "izgladimo", smanjimo dostupanja na minimum gdje god možemo.

5. Iskaži i dokaži teorem o egzistenciji jedinstvenog interpolacijskog polinoma.

Neka su (x_i, y_i) , $i = 0, \dots, n$ takve da je $a = x_0 < x_1 < \dots < x_n = b$. Tada postoji jedinstveni polinom $P_n : [a, b] \rightarrow \mathbb{R}$ takav da je $\deg P_n \leq n$ i $\forall i = 0, \dots, n$ vrijedi: $P_n(x_i) = y_i$.

Puni dokaz možete pronaći u objavljenj skripti, evo skice:

- polinom zapišemo kao sumu potencija x^k i pripadnih koeficijenata a_k , $k = 0, \dots, n$, $a_n \neq 0$
- zbog posljednjeg uvjeta u teoremu, raspíšemo sustav $(n+1) \times (n+1)$ linearnih jednažbi, gdje su koeficijenti polinoma nepoznanice
- prelaskom u matrični zapis primijetimo Vandermondeovu matricu
- determinanta joj nije nula jer su svi x_i međusobno različiti
- matrica je regularna, pa onda postoji jedinstveno rješenje

6. Konstruiraj Lagrangeov i Newtonov oblik interpolacijskog polinoma

Lagrangeov interpolacijski polinom:

- Konstruiramo pomoćne funkcije $p_i : [a, b] \rightarrow \mathbb{R}$ za $i = 0, \dots, n$
- na kraju, te funkcije ispadnu oblika:

$$p_i(x) = \frac{(x - x_0)(x - x_1) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n)}{(x_i - x_0)(x_i - x_1) \dots (x_i - x_{i-1})(x_i - x_{i+1}) \dots (x_i - x_n)}$$

- u sumi, interpolacijski polinom izgleda kao $P_n = \sum_{i=0}^n y_i p_i(x)$

Newtonov interpolacijski polinom:

- Započnemo sa klasičnom razdiobom segmenta $a = x_0 < x_1 < \dots < x_n = b$ te za uvjete uzmemo $P_n(x_i) = y_i$, $\forall i = 0, \dots, n$
- izračunamo potrebne **podijeljene razlike**, npr. podijeljenu razliku k-tog reda:

$$f[x_0, x_1, \dots, x_k] = \frac{f[x_1, \dots, x_k] - f[x_0, \dots, x_{k-1}]}{x_k - x_0}$$

- za neki općeniti polinom stupnja n , Newtonov oblik interpolacijskog polinoma će izgledati kao:

$$P_n(x) = f[x_0] + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots + f[x_0, \dots, x_n] \prod_{i=0}^{n-1} (x - x_i)$$

7. Definiraj spline; Postavi uvjete i izvedi formule za linearni i kubični spline

Spline - najčešće polinom (generalno nižeg stupnja, a ne mora biti ni polinom) kojim na jednom malom dijelu promatranog intervala interpoliramo neku funkciju; takvom interpolacijom po dijelovima postižu se manja odstupanja u interpolaciji.

Linearni interpolacijski spline

- zadana je funkcija $f : [a, b] \rightarrow \mathbb{R}$ i razdioba segmenta $[a, b]$
- Mora vrijediti:

$$\phi_i(x_{i-1}) = f(x_{i-1}) = y_{i-1}, \phi_i(x_i) = f(x_i) = y_i$$

- onda cijeli interpolacijski spline ϕ definiramo kao funkciju po dijelovima sa odgovarajućim ϕ_i na $[x_{i-1}, x_i]$, $\forall i = 0, \dots, n$

Kubični interpolacijski spline

- Opet, definiramo ga kao funkciju po dijelovima, gdje je svaki dio kubični polinom $c_i(x) = a_i x^3 + b_i x^2 + c_i x + d_i$
- dakle, moramo odrediti $4n$ koeficijenata, ali sa uvjetima da funkcijske vrijednosti pašu u odgovarajućim čvorovima i derivacije u čvorovima da budu jednake, dobivamo samo $4n - 2$ uvjeta
- stoga dodajemo tkz. **prirodne uvjete**, tj., da su druge derivacije u posljednjem i zadnjem čvoru jednake nuli
- tada, dobivamo sljedećih $4n$ uvjeta:

$$\begin{cases} c_i(x_{i-1}) = y_{i-1}, & i = 1, \dots, n \\ c_i(x_i) = y_i, & i = 1, \dots, n \\ c'_i(x_i) = c'_{i+1}(x_i), & i = 1, \dots, n-1 \\ c''_i(x_i) = c''_{i+1}(x_i), & i = 1, \dots, n-1 \\ c'_1(x_0) = 0 \\ c''_n(x_n) = 0 \end{cases}$$

8. Izvedi formulu za pogrešku kod linearnog splinea

- Pretpostavimo da imamo klasičnu razdiobu intervala $[a, b]$ te se ograničimo na neki $[x_{i-1}, x_i]$
- tada, za neki x iz tog intervala, budući da gledamo interpolacijski polinom između dvije točke, po teoremu 2.2 (vidi skriptu) znamo da vrijedi:

$$|f(x) - \phi(x)| = |f(x) - \phi_i(x)| \leq \frac{M_2}{2!} \max_{x \in [x_{i-1}, x_i]} |(x - x_{i-1})(x - x_i)|$$

Uočimo kako je $\max_{x \in [x_{i-1}, x_i]} |(x - x_{i-1})(x - x_i)|$ zapravo tjeme parabole (ali s pozitivnim koordinatama zbog apsolutne vrijednosti), što će biti funkcijska vrijednost u aritmetičkoj sredini točaka x_{i-1} i x_i . Dakle, imamo

$$\begin{aligned} |f(x) - \phi_i(x)| &\leq \frac{M_2}{2!} \left| \left(\frac{x_{i-1} + x_i}{2} - x_{i-1} \right) \left(\frac{x_{i-1} + x_i}{2} - x_i \right) \right| = \frac{M_2}{2!} \cdot \frac{(x_i - x_{i-1})^2}{4} \\ &= \frac{M_2}{8} (x_i - x_{i-1})^2 \end{aligned}$$

Neka je $h_i := x_i - x_{i-1}$, sada imamo

$$|f(x) - \phi_i(x)| \leq \frac{M_2}{8} h_i^2.$$

Sada ako bismo htjeli naći h_i takav da za svaku ϕ_i vrijedi $|f(x) - \phi_i(x)| < \varepsilon$, samo uzmemo $h_{\max} := \max_{i=1, \dots, n} h_i$. Kako će tada nejednakost vrijediti za sve ϕ_i , vrijedit će općenito i za ϕ . Za ekvidistantnu razdiobu vrijedit će $h_{\max} = h = \frac{b-a}{n}$, pa bismo imali

$$|f(x) - \phi(x)| \leq \frac{M_2}{8} h^2 = \frac{M_2}{8} \left(\frac{b-a}{n} \right)^2.$$

9. Definiraj brzinu konvergencije numeričke metode i navedi primjere

Brzina konvergencije

Neka je $(x_n)_{n \in \mathbb{N}}$ niz definiran nekom metodom koji konvergira $\xi \in \mathbb{R}$ te neka je $e_n = x_n - \xi$ pogreška n -te aproksimacije. Tada, ako postoje $A, r > 0$ takvi da vrijedi:

$$|e_{n+1}| \leq A|e_n|^r A, \quad \forall x_n \geq x_1$$

kažemo da metoda ima **brzinu konvergencije r** .

Metoda bisekcije i metoda jednostavnih iteracija imaju linearnu (1) brzinu konvergencije, dok npr. Newtonova metoda tangenti ima kvadratnu (2) brzinu konvergencije.

10. Objasni metodu bisekcije te izvedi ocjenu pogreške

- Pretpostavimo da moramo riješiti $f(x) = 0$, gdje rješenje ne možemo točno odrediti
- metodom bisekcije aproksimaciju rješenja nalazimo na sljedeći način:
- definiramo početne a_0, b_0 te prvu aproksimaciju rješenja, $x_1 := \frac{a_0+b_0}{2}$ pa ako je $f(x_1) = 0$, našli smo rješenje
- u suprotnom, definiramo nova dva ruba (vidi skriptu za detalje) pazeći da je $f(\text{lijevi}) \cdot f(\text{desni}) < 0$, $x_2 := \frac{\text{lijevi} + \text{desni}}{2}$
- ponavljamo dok ne dođemo do točnog rješenja ξ ili dovoljno male pogreške aproksimacije

Ocjena pogreške metode bisekcije.

Budući da znamo da je ξ negdje unutar našeg početnog intervala $[a_0, b_0]$ možemo zaključiti kako je $|\xi - x_1| \leq \frac{b_0 - a_0}{2}$, a za neki x_n , $|\xi - x_{n+1}| \leq \frac{1}{2}|\xi - x_n|$ (pogreška sljedeće aproksimacije je uvijek pola ili manje od prošle pogreške, nacrtajte si ako ne vidite na pravcu).

Dakle, slijedi nam niz nejednakosti:

$$0 \leq |\xi - x_n| \leq \frac{1}{2}|\xi - x_{n-1}| \leq \frac{1}{4}|\xi - x_{n-2}| \leq \dots \leq \frac{1}{2^{n-1}}|\xi - x_1| \leq \frac{1}{2^n}(b_0 - a_0)$$
$$\implies |\xi - x_n| \leq \frac{1}{2^n}(b_0 - a_0)$$

11. Objasni metodu jednostavnih iteracija

- našu početnu jednadžbu $f(x) = 0$ zapišemo u obliku $\phi(x) = x$, čiji zapis nije jedinstven, postoji više opcija s obzirom na zadani f
- sada kao rješenje zadatka tražimo fiksne točke funkcije ϕ i zadammo si neku početnu aproksimaciju x_0
- sljedeću aproksimaciju definiramo kao $x_1 := \phi(x_0)$ intuitivno, $x_n \rightarrow \xi$, ali je ipak važno kakvu funkciju ϕ i početnu aproksimaciju odaberemo
- o potrebnim uvjetima više u teoremu

Konvergencija metode jednostavnih iteracija

Neka je $\varphi : [a, b] \rightarrow \mathbb{R}$ neprekidno diferencijabilna funkcija na $[a, b]$ za koju vrijedi

- (a) $\varphi(x) \in [a, b]$, $(\forall x \in [a, b])$,
- (b) $(\exists q \in (0, 1)) \quad |\varphi'(x)| \leq q \quad (\forall x \in [a, b])$.

Onda postoji jedinstveni $\xi \in [a, b]$ takav da je $\xi = \varphi(\xi)$. Nadalje, niz $x_n = \varphi(x_{n-1})$ konvergira prema ξ za svaki izbor $x_0 \in [a, b]$. Pri tome vrijedi $|\xi - x_n| \leq \frac{q^n}{1-q}|x_1 - x_0|$, odnosno $|\xi - x_n| \leq \frac{q}{1-q}|x_n - x_{n-1}|$. Može se pokazati da metoda jednostavnih iteracija ima linearnu brzinu konvergencije i da vrijedi

$$|\xi - x_{n+1}| \leq q \cdot |\xi - x_n|.$$

Za potpuni dokaz teorema vidi skriptu, evo skice za svaki dio dokaza:

- (a) Dokaz konvergencije niza $(x_n)_{n \in \mathbb{N}}$
- raspišemo razliku $x_{n+1} - x_n$ pomoću razlike ϕ -eva te na nju iskoristimo Lagrangeov teorem
 - prelaskom na apsolutnu vrijednost dobijemo $|x_{n+1} - x_n| \leq q|x_n - x_{n-1}|$
 - ponavljamo postupak dok ne dođemo do $q^n \cdot |x_1 - x_0|$
 - nakon toga iskoristimo "foru" sa zadanim redom brojeva te pomoću prošlog svojstva nađemo njegovu konvergentnu majorantu, iz čega zaključimo da je i njegov niz parcijalnih suma (koji je baš naš početni niz) konvergentan
 - iz toga znamo da limes niza postoji pa napadnemo jednakost $x_n = \phi(x_{n-1})$ limesom, i zbog neprekidnosti ϕ dobijemo $\xi = \phi(\xi)$
- (b) Dokaz o jedinstvenosti nultočke je vrlo kratak, pretpostavi se suprotno i opet iskoristi Lagrange na ϕ razlici, vidi skriptu za detalje
- (c) Dokaz pogreške n-te aproksimacije
- Promotrimo sljedeći niz nejednakosti

$$\begin{aligned}
 |x_{n+p} - x_n| &= |x_{n+p} - x_{n+p-1} + x_{n+p-1} - x_{n+p-2} + x_{n+p-2} + \cdots - x_{n+1} + x_{n+1} - x_n| \\
 &\leq |x_{n+p} - x_{n+p-1}| + |x_{n+p-1} - x_{n+p-2}| + \cdots + |x_{n+1} - x_n| \\
 &\leq q^{n+p-1} \cdot |x_1 - x_0| + q^{n+p-2} \cdot |x_1 - x_0| + \cdots + q^n \cdot |x_1 - x_0| \\
 &= q^n \cdot |x_1 - x_0| \cdot \sum_{i=1}^p q^{p-i} = q^n \cdot |x_1 - x_0| \cdot \frac{1 - q^p}{1 - q}
 \end{aligned}$$

Sada imamo

$$\begin{aligned}
 |x_{n+p} - x_n| &\leq \frac{q^n}{1 - q} |x_1 - x_0| (1 - q^p) \\
 \lim_{p \rightarrow \infty} |x_{n+p} - x_n| &\leq \frac{q^n}{1 - q} |x_1 - x_0| \lim_{p \rightarrow \infty} (1 - q^p) \\
 \xrightarrow{q < 1} |\xi - x_n| &\leq \frac{q^n}{1 - q} |x_1 - x_0|
 \end{aligned}$$

12. Objasni Newtonovu metodu tangenti, iskaži i dokaži teorem o konvergenciji

- promatramo funkciju $f : [a, b] \rightarrow \mathbb{R}$ za koju je $f(a) \cdot f(b) < 0$, odnosno nultočka se nalazi na intervalu $\langle a, b \rangle$
- odaberemo neki $x_0 \in [a, b]$. U x_0 povlačimo tangentu na funkciju f (pri čemu f mora biti klase $C^1([a, b])$). Jednadžba te tangente dana je izrazom:

$$t_0(x) = f(x_0) + f'(x_0)(x - x_0).$$

- rješavamo jednadžbu $t_0(x) = 0$:

$$\begin{aligned}
 f(x_0) + f'(x_0)(x - x_0) &= 0 \\
 x - x_0 &= -\frac{f(x_0)}{f'(x_0)} \\
 x &= x_0 - \frac{f(x_0)}{f'(x_0)} := x_1
 \end{aligned}$$

- Sada povlačimo tangentu u točki x_1 i ponavljamo postupak. Ponavljanjem postupka dobivamo niz $(x_n)_{n \in \mathbb{N}}$ dan izrazom

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

pri čemu je x_0 početna aproksimacija rješenja jednadžbe $f(x) = 0$

Teorem o konvergenciji Newtonove metode tangenti:

Neka je $f : I = [a, b] \rightarrow \mathbb{R}$ i $f \in C^2(I)$ te $f(a) \cdot f(b) < 0$ i f', f'' na I imaju stalni predznak (strogo su monotone, pa je nultočka jedinstvena). Onda, ako je $x_0 \in I$ takav da je $f(x_0) \cdot f''(x_0) > 0$, niz $(x_n)_{n \in \mathbb{N}}$ definiran s

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}, \quad n = 0, 1, 2, \dots$$

konvergira prema jedinstvenoj nultochki ξ od f . Pritom vrijedi

$$|\xi - x_n| \leq \frac{M_2}{2m_1}(x_n - x_{n-1})^2, \quad M_2 = \max_{x \in I} |f''(x)|, \quad m_1 = \min_{x \in I} |f'(x)|.$$

Ovdje će biti data samo skica dokaza, za potpuni i detaljni vidi skriptu

(a) Dokaz konvergencije niza

- derivacije moraju biti konstantnog predznaka na intervalu, stoga BSO pretpostavimo da su i prva i druga derivacija veće od nule na intervalu
- dokaz se izvrši putem MMI, s čime se dokaže da niz ima donju među koja je upravo ξ
- za početak, funkcija se u koraku indukcije (gdje gledamo x_{k+1}) razvije oko točke x_k ,

$$f(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{f''(c)}{2}(x - x_k)^2$$

- kada uvrstimo $x = \xi$, lijeva strana postane nula, a zadnji član je sigurno veći od nule pa se on makne u nejednadžbi
- na kraju dobijemo

$$\xi < x_k - \frac{f(x_k)}{f'(x_k)} = x_{k+1}$$

- sada treba dokazati da je niz monotono padajuć, što bude očito kada se uzme razlika $x_{n+1} - x_n$
- dobije se rezultat $-\frac{f(x_n)}{f'(x_n)}$, što je sigurno negativno jer znamo da su oba člana u razlomku pozitivna, pa iz ovoga slijedi da je niz padajuć
- pokazali smo da je niz (x_n) konvergentan i da postoji $\bar{\xi}$ takav da je $\lim_{n \rightarrow \infty} x_n = \bar{\xi}$. Pokažimo sada da je $\bar{\xi}$ rješenje jednadžbe $f(x) = 0$, odnosno $\bar{\xi} = \xi$

$$\begin{aligned} x_{n+1} &= x_n - \frac{f(x_n)}{f'(x_n)} \\ \xrightarrow{n \rightarrow \infty} \bar{\xi} &= \bar{\xi} - \frac{f(\bar{\xi})}{f'(\bar{\xi})} \\ f(\bar{\xi}) &= 0 \implies \bar{\xi} = \xi. \end{aligned}$$

(b) sada još treba pokazati

$$|\xi - x_n| \leq \frac{M_2}{2m_1} |x_n - x_{n-1}|^2$$

- prvo se preko Lagrangeova teorema dokaže $|\xi - x_n| \leq \frac{|f(x_n)|}{m_1}$ tako da se on primjeni na razliku $f(\xi) - f(x_n)$
- zatim se putem Taylora razvije brojnik do druge derivacije u nekoj točki c , pa se $|f(x_n)|$ omeđi sa $\frac{M_2}{2} |x_n - x_{n-1}|^2$

(c) traženi dokaz dolazi kombinacijom oboje

13. Izvedi newtonovu metodu za rješavanje sustava nelinearnih jednadžbi

Ovdje ide Newtonova metoda

14. Objasni problem aproksimacije funkcija s linearnom kombinacijom nezavisnih funkcija

- Neka je $f : [a, b] \rightarrow \mathbb{R}$ dana funkcija koju želimo zamijeniti s jednostavnijom funkcijom $g : [a, b] \rightarrow \mathbb{R}$ takvom da je $g \approx f$ na $[a, b]$

- cilj nam je minimizirati udaljenost $\|f - g\| = \sqrt{\int [f(x) - g(x)]^2 dx}$

- uzimajući neki ortogonalan sustav funkcija, gledamo kako g zapisati kao neku njihovu linearnu kombinaciju, pa se problem minimiziranja udaljenosti svodi na pronalaženje optimalnih koeficijenata $a_0, \dots, a_n$
- tada naša udaljenost postaje kriterijska funkcija

$$F(a_0, \dots, a_n) = \|f - g\|$$

gdje naravno umjesto korijena gledamo samo kvadrate udaljenosti zato što to dovede do istog rezultata, a olakšava posao

- kako tražimo minimum te funkcije, moramo ju parcijalno derivirati po svim varijablama te to izjednačiti s nulom, čime dobivamo sustav $(n+1) \times (n+1)$
- zapisom toga sustava u matricnom obliku primijetimo da dobijemo Gramovu matricu, sa kojom dalje možemo raditi i određivati postoji li jedinstveno rješenje.

Apsolutno mi se ne da pisati još o Fourieru, pogledajte u bilježnici kako s njime aproksimiramo, i pogledajte jedan YouTube video koji to prikaže na slici i to vam je dovoljno.

15. Objasni kako neki pravac u LS smislu najbolje aproksimira neki set podataka

- Pretpostavimo da imamo neki set podataka $(x_i, y_i), i = 1, \dots, m$
- LS pravac je onaj za koji je suma vertikalnih udaljenosti između tog pravca i zadanih vrijednosti u čvorovima x_i minimalna
- pravac uvijek postoji, čim nekakvi podaci postoje, a biti će jedinstven ako postoje barem dva x_i, x_j takvi da $x_i \neq x_j$

16. Formuliraj opći linearni problem najmanjih kvadrata

- Zadana je matrica $J \in M_{mn}, m \gg n$ te $y \in \mathbb{R}^n$
- treba odrediti $a \in \mathbb{R}^n$ takav da je $\|Ja - y\|$ minimalna po $a \in \mathbb{R}^n$

17. Razne metode za rješavanje LPNK

Metoda normalnih jednadžbi

- pretpostavimo da imamo klasičnu funkciju sa parametrima i gledamo vektor reziduala:

$$r_i(a_0, a_1) = y_i - f(x_i; a_0, a_1)$$

$$\implies \mathbf{r} = \mathbf{y} - a_0 \mathbf{J}_1 - a_1 \mathbf{J}_2$$

- onda nam cilj postaje minimizirati normu vektora $\mathbf{r}$, pa definiramo funkciju $F(a) = \frac{1}{2} \|\mathbf{r}\|_2^2$
- za minimizaciju trebamo izjednačiti gradijent funkcije sa nulom, pa dobijemo jednadžbe:

$$\mathbf{J}_1^T \cdot \mathbf{r} = 0, \mathbf{J}_2^T \cdot \mathbf{r} = 0$$

- zatim to malo proširimo tako da vektor reziduala zamijenimo sa onom razlikom s kojom je definiran par redaka gore
- na kraju dobijemo sustav koji možemo pretvoriti u matricni zapis:

$$\begin{cases} a_0 \mathbf{J}_1^T \mathbf{J}_1 + a_1 \mathbf{J}_1^T \mathbf{J}_2 = \mathbf{J}_1^T \mathbf{y} \\ a_0 \mathbf{J}_2^T \mathbf{J}_1 + a_1 \mathbf{J}_2^T \mathbf{J}_2 = \mathbf{J}_2^T \mathbf{y} \end{cases}$$

- općenito za $\mathbf{J} \in \mathbb{R}^{m \times n}$ dobijemo tzv. sustav normalnih jednadžbi

$$\mathbf{J}^T \mathbf{J} \mathbf{a} = \mathbf{J}^T \mathbf{y}$$

- rješenje je jedinstveno ako su $\mathbf{J}_1, \mathbf{J}_2$ linearno nezavisni

QR dekompozicija

- znamo da imamo

$$\|\mathbf{r}(\mathbf{a})\|_2^2 = \|\mathbf{J}\mathbf{a} - \mathbf{y}\|_2^2 = \|\mathbf{Q}\mathbf{R}\mathbf{a} - \mathbf{y}\|_2^2 = \|\mathbf{Q}(\mathbf{R}\mathbf{a} - \mathbf{Q}^T\mathbf{y})\|_2^2 = \|\mathbf{R}\mathbf{a} - \mathbf{Q}^T\mathbf{y}\|_2^2$$

- sada nam je opet cilj minimizirati normu vektora na kraju jednakosti
- neka je $\mathbf{Q} = [\mathbf{Q}_n \quad \mathbf{Q}_{m-n}]$
- tada znamo da vrijedi:

$$\|\mathbf{R}\mathbf{a} - \mathbf{Q}^T\mathbf{y}\|_2^2 = \left\| \begin{bmatrix} \mathbf{R}_n \\ 0 \end{bmatrix} \mathbf{a} - \begin{bmatrix} \mathbf{Q}_n^T \\ \mathbf{Q}_{m-n}^T \end{bmatrix} \mathbf{y} \right\|_2^2 = \underbrace{\|\mathbf{R}_n\mathbf{a} - \mathbf{Q}_n^T\mathbf{y}\|_2^2}_{\geq 0} + \|\mathbf{Q}_{m-n}^T\mathbf{y}\|_2^2 \geq \|\mathbf{Q}_{m-n}^T\mathbf{y}\|_2^2$$

- iz čega možemo iščitati da ta norma ima neku donju granicu, koju postiže kada je $\|\mathbf{R}_n\mathbf{a} - \mathbf{Q}_n^T\mathbf{y}\|_2^2$ minimalna
- iz toga, zaključujemo da će norma biti minimalna za neki $\mathbf{a}^*$ za koji vrijedi:

$$\begin{aligned} \mathbf{R}_n\mathbf{a}^* &= \mathbf{Q}_n^T\mathbf{y} \\ \implies \mathbf{a}^* &= \mathbf{R}_n^{-1}\mathbf{Q}_n^T\mathbf{y} \end{aligned}$$

- pri čemu je $\mathbf{Q}_n^T$ prvih n redaka matrice $\mathbf{Q}^T$, odnosno $\mathbf{Q}_n$ je prvih n stupaca matrice $\mathbf{Q}$

SVD dekompozicija

- kao i kod QR, originalnu matricu $\mathbf{J}$ rastavimo na umnožak nekih drugih
- tada u onu funkciju koju minimiziramo, $\|\mathbf{r}\|_2^2$, $\mathbf{J}$ matricu zamijenimo sa njenom dekompozicijom, i opet tražimo donju među te norme
- dobijemo neki rezultat pozitivne norme pa opet samo tražimo kada on doseže nulu, ili sljedeće:
- neka je $\mathbf{J} \in \mathbb{R}^{m \times n}$, $r = \text{rang}(\mathbf{J})$ i $\mathbf{y} \in \mathbb{R}^m$, imamo

$$\begin{aligned} F(\mathbf{a}) &= \|\mathbf{J}\mathbf{a} - \mathbf{y}\|_2^2 = \|\mathbf{U}\Sigma\mathbf{V}^T\mathbf{a} - \mathbf{y}\|_2^2 = \|\mathbf{U}^T(\mathbf{U}\Sigma\mathbf{V}^T\mathbf{a} - \mathbf{y})\|_2^2 \\ &= \|\Sigma\mathbf{V}^T\mathbf{a} - \mathbf{U}^T\mathbf{y}\|_2^2 \stackrel{\mathbf{V}^T\mathbf{a}=\mathbf{z}}{=} \|\Sigma\mathbf{z} - \mathbf{U}^T\mathbf{y}\|_2^2 \\ &= \left\| \begin{bmatrix} \sigma_1 z_1 \\ \sigma_2 z_2 \\ \vdots \\ \sigma_r z_r \\ 0 \\ \vdots \\ 0 \end{bmatrix} - \begin{bmatrix} \mathbf{u}_1^T\mathbf{y} \\ \mathbf{u}_2^T\mathbf{y} \\ \vdots \\ \mathbf{u}_r^T\mathbf{y} \\ \mathbf{u}_{r+1}^T\mathbf{y} \\ \vdots \\ \mathbf{u}_m^T\mathbf{y} \end{bmatrix} \right\|_2^2 = \left\| \begin{bmatrix} \sigma_1 z_1 - \mathbf{u}_1^T\mathbf{y} \\ \sigma_2 z_2 - \mathbf{u}_2^T\mathbf{y} \\ \vdots \\ \sigma_r z_r - \mathbf{u}_r^T\mathbf{y} \end{bmatrix} \right\|_2^2 + \left\| \begin{bmatrix} \mathbf{u}_{r+1}^T\mathbf{y} \\ \mathbf{u}_{r+2}^T\mathbf{y} \\ \vdots \\ \mathbf{u}_m^T\mathbf{y} \end{bmatrix} \right\|_2^2 \geq \sum_{i=r+1}^m (\mathbf{u}_i^T\mathbf{y})^2 \end{aligned}$$

- Uočimo kako smo pronašli donju granicu za F , pa će ona biti minimalna za onaj $\mathbf{z}^*$ za koji su njegove komponente jednake

$$\begin{aligned} \sigma_i z_i^* &= \mathbf{u}_i^T\mathbf{y} \\ z_i^* &= \frac{\mathbf{u}_i^T\mathbf{y}}{\sigma_i} \end{aligned}$$

- tu nam dolaze dva slučaja, kada je rang matrice $\mathbf{J}$ pun i kada nije
- kada NIJE, imamo samo prvih r komponenti od $\mathbf{a}$ pa kako bi norma bila što manja, za ostale komponente biramo nule
- kada rang JE pun, onda su komponente od $\mathbf{a}$ jednoznačno određene:

$$\mathbf{a}^* = \mathbf{V}\mathbf{z}^* = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_n] \cdot \begin{bmatrix} \frac{\mathbf{u}_1^T\mathbf{y}}{\sigma_1} \\ \frac{\mathbf{u}_2^T\mathbf{y}}{\sigma_2} \\ \vdots \\ \frac{\mathbf{u}_n^T\mathbf{y}}{\sigma_n} \end{bmatrix} = \sum_{i=1}^n \frac{\mathbf{v}_i \mathbf{u}_i^T\mathbf{y}}{\sigma_i}$$

18. Formuliraj nelinearni problem najmanjih kvadrata

- pretpostavimo da imamo skup podataka $(x_i, y_i), i = 1, \dots, m$
- uz to, neka naša model-funkcija više nije pravac neko nekakava nelinearna, npr $f(x; a, b) = ae^{bx_i} - y_i$
- tada, funkcija udaljenosti koju želimo minimizirati postaje $F(a, b) = \frac{1}{2} \sum_{i=1}^m (f(x_i; a, b) - y_i)^2$
- i upravo nju želimo minimizirati po (a, b)
- *i nemojte da vas zbuni ona polovina ispred, to se stavi samo da ona dvojka iz derivacije odmah nestane, to je "kozmetički" dodatak*

19. Formuliraj matičnu normu

Frobeniusova norma matrice

Definiramo Frobeniusovu normu matrice $\mathbf{A} \in \mathbb{R}^{n \times n}$ na sljedeći način:

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}$$

gdje su $a_{ij} = [\mathbf{A}]_{ij}$ elementi na presjeku i -tog retka i j -tog stupca matrice.

Matrična norma

Definiramo p -normu matrice $\mathbf{A} \in \mathbb{R}^{n \times n}$ na sljedeći način:

$$\|\mathbf{A}\|_p = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|_p}{\|\mathbf{x}\|_p}$$

20. Objasni uvjetovanost matrice i daj primjer loše uvjetovano matrice

- Pod uvjetovanost, mislimo na pitanje kada malo promijenimo vektor rezultata nekog sustava $\mathbf{b}$, koliko će se promijeniti naš vektor rješenja $\mathbf{x}$
- uvjetovanost nekog sustava određujemo pomoću **kondicije matrice**
- Broj $\|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|$ nazivamo **kondicija matrice** i označavamo s $\text{cond}(\mathbf{A})$. Ako je $\text{cond}(\mathbf{A}) \approx 1$, mala promjena na desnoj strani uzrokovat će malu promjenu u rješenju, pa kažemo da je taj sustav dobro uvjetovan. U suprotnom kažemo da je loše uvjetovan. Specijalno za euklidsku kondiciju vrijedi:

$$\text{cond}_2(\mathbf{A}) = \|\mathbf{A}\|_2 \cdot \|\mathbf{A}^{-1}\|_2 = \sigma_{\max} \cdot \frac{1}{\sigma_{\min}} = \frac{\sigma_{\max}}{\sigma_{\min}}$$

- primje loše uvjetovane matrice je Vandermondeova matrica

21. Objasni trapeznu formulu u integraciji te izvedi rezultat za njenu pogrešku

- trapeznom formulom područje ispod grafa funkcije aproksimiramo kao jedan trapez nad nekim intervalom $[a, b]$
- onda su osnovice toga intervala dužine $f(a), f(b)$ a visina mu je duljina toga intervala
- tada, integral funkcije nad segmentom možemo aproksimirati sa površinom trapeza:

$$I = \int_a^b f(x)dx \approx \frac{f(a) + f(b)}{2} \cdot (b - a)$$

Pogreška trapezne formule:

$$|\Delta I^*| = |I - I^*| \leq \frac{(b-a)^3}{12} M_2$$

- dokaz je duži pa evo samo skice
- primijetimo da mi ovdje tehnički radimo interpolaciju sa samo jednim pravcem, polinomom stupnja 1

- onda, po teoremu 2.2, znamo da postoji $x_x \in \langle a, b \rangle$ takav da za čvorove interpolacije a, b vrijedi:

$$f(x) - P_1(x) = \frac{f''(c_x)}{2}(x-a)(x-b)$$

- kada pređemo na integral, gledamo integral tog umnoška funkcija, koji inače ne znamo riješiti
- tada iskoristimo teorem o srednjoj vrijednosti sa integralnog računa:

$$\int_a^b f(x)g(x)dx = f(c) \int_a^b g(x)dx$$

- to jest, onu drugu derivaciju od f izbacimo i zamijenimo sa nekom točkom $c \in \langle a, b \rangle$
- pod integralom ostane jednostavan polinom, koji nakon integracije postane onaj razlomak sa dvanaestinom
- time imamo nekakvu razliku između funkcije i trapeza, pa na to lupimo apsolutnu vrijednost, i umjesto da gledamo drugu derivaciju u nekoj nasumičnoj točki c , ograničimo tu vrijednost sa većom, M_2 i otuda dolazi naša formula

22. Izvedi produljenu trapeznu formulu

- kako je pogreška obične trapezne formule česte prevelika, zamislimo da podijelimo naš segment u n dijelova, to jest, $n+1$ čvorova
- tada, koristimo trapeznu formulu na svakom intervalu, tako da stavimo $h = \frac{b-a}{n}$, pa vrijedi:

$$I_{[x_{i-1}, x_i]} = \int_{x_{i-1}}^{x_i} f(x)dx = \frac{h}{2}(y_{i-1} + y_i) - \frac{h^3}{12}f''(c_i), \quad y_i = f(x_i), c_i \in \langle x_{i-1}, x_i \rangle$$

- ukupan integrala onda dobivamo sumiranjem po svim $i = 1, \dots, n$

$$I^* = \sum_{i=1}^n \int_{x_{i-1}}^{x_i} f(x)dx = \frac{h}{2}(y_0 + 2 \sum_{i=1}^{n-1} y_i + y_n) - \frac{h^3}{12} \sum_{i=1}^n f''(c_i)$$

- Uočimo kako je $h^3 = h^2 \cdot \frac{b-a}{n}$, a kako je f neprekidna na $[a, b]$ postoji $c \in \langle a, b \rangle$ takav da je

$$\frac{1}{n} \sum_{i=1}^n f''(c_i) = f''(c)$$

pa imamo

$$I = \frac{h}{2} \left(y_0 + 2 \sum_{i=1}^{n-1} y_i + y_n \right) - \frac{b-a}{12} h^2 f''(c)$$

pri čemu je

$$I^* = \frac{h}{2} \left(y_0 + 2 \sum_{i=1}^{n-1} y_i + y_n \right)$$

- iz toga, možemo vidjeti da pogrešku možemo omediti sa

$$|\Delta I^*| \leq \frac{b-a}{12} h^2 M_2$$

a onda je naša aproksimacija prethodna razlika, samo bez zadnjeg dijela

23. Objasni Newton Cotesove formule

- cilj Newton-Cotesovih formula je numerički integrirati funkciju, ali umjesto linearnih splineova koristimo polinome višeg stupnja
- time, na manjim intervalima dobivamo veću točnost aproksimiranog integrala
- ideja je na nekom segmentu $[a, b]$ napraviti razdiobu na n podsegmenata, tj., promatrati $n + 1$ čvor
- za udaljenost između čvorova stavimo da je ekvidistantna, tj. $h = \frac{b-a}{n}$, a potom funkciju interpoliramo lagrangeovim polinomom stupnja n :

$$f(x_k) = y_k, \quad P_n(x) = \sum_{k=0}^n y_k p_k(x)$$

$$p_k(x) = \prod_{\substack{i=0 \\ i \neq k}}^n \frac{x - x_i}{x_k - x_i}$$

- tada naš integral funkcije f možemo aproksimirati kao:

$$I^* = \int_a^b f(x) dx \approx \int_a^b \sum_{k=0}^n y_k p_k(x) dx$$

- prije nastavka, rezultat će se pomnožiti s $\frac{b-a}{b-a}$ koji se razdvoji kako bi olakšao integraciju, pa vrijedi:

$$I^* \approx (b-a) \sum_{k=0}^n y_k \int_a^b p_k(x) dx$$

$$I^* \approx (b-a) \sum_{k=0}^n \omega_k y_k$$

- gdje su

$$\omega_k = \frac{1}{b-a} \int_a^b \prod_{\substack{i=0 \\ i \neq k}}^n \frac{x - x_i}{x_k - x_i} dx = \left| \frac{x = a + (b-a)t}{dx = (b-a) dt} \right| = \int_0^1 \prod_{\substack{i=0 \\ i \neq k}}^n \frac{nt - i}{k - i} dt$$

Simpsonova formula

- Simpsonova formula slijedi iz prošlih kada stavimo da je $n = 2$, pa tada imamo razdiobu $x_0 = a, x_1 = \frac{a+b}{2}, x_2 = b$
- izračunamo pripadne težine $\omega_0, \omega_1, \omega_2$ te ih samo uvrstimo u formulu i dobijemo:

$$I^* \approx \frac{b-a}{6} \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right)$$

24. Izvedi produljenu Simpsonovu formulu

- kod produljene formule ideja je podijeliti segment na paran broj podsegmenata, $n = 2m$ te onda po svaka dva koristiti Simpsonovu formulu
- iliti, malo slikovito i puno matematički netočno:

$$I^* = \text{Simpson}(1. \text{ i } 2. \text{ interval}) + \text{Simpson}(3. \text{ i } 4. \text{ interval}) + \dots + \text{Simpson}(\text{predzadnji i zadnji interval})$$

$$I^* = \sum_{k=0}^{m-1} I^*_{[x_{2k}, x_{2k+1}], [x_{2k+1}, x_{2k+2}]} = \sum_{k=0}^{m-1} \frac{h}{3} (y_{2k} + 4y_{2k+1} + y_{2k+2})$$

$$I^* = \frac{h}{3} (y_0 + 4(y_1 + \dots + y_{2m-1}) + 2(y_2 + \dots + y_{2m-2}) + y_{2m})$$